


1.1 분류 기준



데이터 분류는 성능심의 가이드라인 참조해서

- 1) 소방활동 접근성 분야
- 2) 소방시설(기계/전기) 분야
- 3) 건축 피난/방재 분야
- 4) 화재/피난 시뮬레이션 분야
- 5) 반도체 분야
- 6) 도로터널 분야

로 나눴습니다.

근데 읽다보니까 분류가 안써져있는 자료도 몇 개 있더라구요

2022	1	19	부산진구 범천동 복합시설 신축공사	성능위주	1자	소방 활동접근성 분야
2022	1	19	부산진구 범천동 복합시설 신축공사	성능위주	1자	소방 활동접근성 분야
2022	1	19	부산진구 범천동 복합시설 신축공사	성능위주	1자	소방 활동접근성 분야
2022	1	19	부산진구 범천동 복합시설 신축공사	성능위주	1자	소방 활동접근성 분야
2022	1	19	부산진구 범천동 복합시설 신축공사	성능위주	1자	소방 활동접근성 분야
2022	1	19	부산진구 범천동 복합시설 신축공사	성능위주	1자	소방 활동접근성 분야

2022년 자료(분류 있음)

	A	B	C	D	E	F	G	H	I
52	번호	년도	월	일	프로젝트명	분류	심의권 / 1자 / 2자	심의위원	가이드-
1		2019	1	10	삼성생명빌딩 증축 및 용도변경	사건재난		하영철 심의위원	
2		2019	1	10	삼성생명빌딩 증축 및 용도변경	사건재난		하영철 심의위원	
3		2019	1	10	삼성생명빌딩 증축 및 용도변경	사건재난		박준욱 심의위원	
4		2019	1	10	삼성생명빌딩 증축 및 용도변경	사건재난		박준욱 심의위원	
5		2019	1	10	삼성생명빌딩 증축 및 용도변경	사건재난		박준욱 심의위원	
6		2019	1	10	삼성생명빌딩 증축 및 용도변경	사건재난		박준욱 심의위원	
7		2019	1	10	삼성생명빌딩 증축 및 용도변경	사건재난		박준욱 심의위원	
8		2019	1	10	삼성생명빌딩 증축 및 용도변경	사건재난		박준욱 심의위원	

2019년 자료 (분류 없음)

그렇다고 저 자료를 생략할 순 없으니 일단 나름의 논리를 세워서 분류표를 붙여줘보겠습니다.

1,2 논리

의견과 조치계획만 읽고 분야를 직접 붙여주기엔 데이터양도 많을뿐더러 제가 그걸 판단할 지능도 없기때문에 explicit, rule, model이라는 규칙을 가지고 저 데이터들을 컴퓨터보고 나눠보라고 지시하겠습니다.

explicit

엑셀의 분야셀 값 자체에 분야명이 직접 들어 있는 경우입니다.(2022년 자료같은)

예를 들어 소방시설 분야, 건축 피난/방재 분야, 반도체 분야 같은 문구가 셀에 있으면 그대로 그 분류를 씁니다.

가장 신뢰도가 높아서 우선순위가 제일 높습니다

rule

explicit만으로는 분류가 안 될 때, 내용 + 조치계획 텍스트 안의 대표 키워드로 점수화해서 분류한 경우입니다.

예를 들어 소방차량, 고가사다리차, 접안이 많이 나오면 소방활동 접근성 분야, 스프링클러, 감지기, 배관이 나오면 소방시설 분야로 보는 식입니다.

model

explicit도 아니고 rule도 애매할 때,

명시 분류가 달린 행들을 학습데이터로 써서 텍스트 분류 모델이 예측한 결과입니다.

즉 explicit 행들로 모델을 학습하고, 남은 애매한 행에 대해 가장 가능성 높은 분야를 고릅니다.

모델확신도 컬럼은 이 예측 확률의 최대값입니다.

정리하면 우선순위는

- 1.explicit 먼저 사용
- 2.없으면 rule
- 3.그래도 없으면 model
- 4.끝까지 비면 fallback

fallback은 사용자가 물어본 3개는 아니지만, 아주 드물게 끝까지 분류가 비는 경우 그냥 그 데이터를 날리는 겁니다. 비율은 저 30000개 중 약 70개 정도로 거의 결측값 수준이라 삭제해도 크게 지장은 없을 것 같습니다.

2, 무슨 키워드를 추출했는지?

명사

한글 150개 언어 ▾

기사 말하다

읽다 편집하다 기록 보기 도구 ▾

위키백과, 자유 백과사전에서 발췌

다른 용례는 [명사\(동음이의\)](#)를 참조하십시오.

문법에서 명사는 생물, 장소, 행위, 속성, 존재 상태, 관념과 같은 구체적이거나 추상적인 사물을 나타내는 단어입니다. 요약하자면, 명사는 사물이 나 관념을 의미합니다. 명사는 **구**, **절**, **문장** 내에서 **목적어** 나 **주어** 역할을 할 수 있습니다. ^[1]^[주1]

요약하면 내용 + 조치계획 텍스트를 Kiwi로 형태소 분석해서, 명사/고유명사/영문 토큰만 남기고, 불용어를 제거한 뒤, 단일 명사와 연속 명사구를 가중치로 집계하는 방식입니다.

핵심 흐름은 이렇습니다.

1) 입력 텍스트

키워드 추출용 원문은 분야셀이 아니라 내용 + 조치계획입니다.

2) 전처리

반복 문구나 행정성 문구를 BOILERPLATE_PATTERNS로 먼저 제거합니다.

3) 어떤 품사만 남기나

허용 품사는 NNG, NNP, SL입니다. 보통명사, 고유명사, 영문/약어예요

4) 불용어 제거

예를 들어 검토, 계획, 성능위주, 피난 안전, 근린 생활 시설 같은 일반성 높은 말들을 걸러냅니다.

5) 용어 정규화

6) 실제 집계 방식

Kiwi.tokenize()라는 함수로 토큰화합니다.

명사 1개는 +1

연속된 명사 2개 구는 +2

연속된 명사 3개 구도 +2

그래서 스프링클러, 설비도 세지만, 붙어서 나온 스프링클러설비가 더 잘 올라오게 설계돼 있습니다.

7) 분야별 top100 생성

먼저 행별로 분야를 분류한 뒤, 각 분야에 속한 행들만 따로 모아서 키워드를 집계합니다.

8) 마지막에 counter.most_common(top_n)으로 상위 100개를 뽑습니다.

3. 데이터 설명

엑셀 파일 열어보면 뭐가 많을텐데 키워드 추세 보려면 그냥 keyword_wide_top100 만 읽으시면 됩니다.

1) Summary_top1

분류	키워드	빈도
건축 피난/방재 분야	방화구획	7408
도로터널 분야	연결통로	118
반도체 분야	반도체공장	20
소방시설(기계/전기) 분야	배관	5442
소방활동 접근성 분야	소방차량	5153
화재/피난 시뮬레이션 분야	연기	1091

분류 별로 제일 많이 나온 키워드 하나씩 뽑았습니다

2) keyword_wide_top100

순위	소방활동 접근성 분야 키워드	빈도	소방시설(기계/전기) 분야 키워드	빈도	건축 피난/방재 분야 키워드	빈도
1	소방차량	5153	배관	5442	방화구획	7408
2	진입	3207	펌프	4791	피난계단	7406
3	소방차	2052	옥내소화전	4678	계단	6492
4	소방관 진입	1942	비상	3503	구획	4720
5	접안	1291	스프링클러	3238	특별 피난 계단	4398
6	고가사다리차	1260	소화전	3205	지하 주차장	3556
7	소방관	1254	시방서	3171	출입문	3442
8	소방 자동차	1026	감지기	2731	주차장	3350
9	부서	1009	방지	2695	구조	3077
10	소방대 진입	966	스프링클러 헤드	2590	승강기	2824

제일 많이 나온 단어 1~100등까지 **가로**로 나열했습니다.
그나마 보기 편합니다

3) keyword_wide_top100

제일 많이 나온 단어 1~100등까지 **세로**로 나열했습니다
나중에 llm 모델 학습할 때 파일 읽기 편하게 할 목적입니다

4) row_counts

분류	행수
소방활동 접근성 분야	3620
소방시설(기계/전기) 분야	14208
건축 피난/방재 분야	11613
화재/피난 시뮬레이션 분야	2358
반도체 분야	21
도로터널 분야	60

분류 기준 데이터 수들
소방시설 분야가 제일 많았습니다

5, source_counts, category_by_source, classified_rows

1	분류출처	건수
2	rule	17717
3	model	9454
4	explicit	4709

source_counts

	A	B	C	D
1	분류	분류출처	건수	
2	건축 피난/방재 분야	explicit	1761	
3	건축 피난/방재 분야	model	3858	
4	건축 피난/방재 분야	rule	5994	
5	도로터널 분야	explicit	18	
6	도로터널 분야	model	1	
7	도로터널 분야	rule	41	
8	반도체 분야	explicit	20	
9	반도체 분야	rule	1	
10	소방시설(기계/전기) 분야	explicit	1724	
11	소방시설(기계/전기) 분야	model	4923	
12	소방시설(기계/전기) 분야	rule	7561	
13	소방활동 접근성 분야	explicit	684	
14	소방활동 접근성 분야	model	538	
15	소방활동 접근성 분야	rule	2398	
16	화재/피난 시뮬레이션 분야	explicit	502	
17	화재/피난 시뮬레이션 분야	model	134	
18	화재/피난 시뮬레이션 분야	rule	1722	
19				

category_by_source

A	B	C	D	E
1	분류	분류출처	건수	
2	건축 피난/방재 분야	explicit	1761	
3	건축 피난/방재 분야	model	3858	
4	건축 피난/방재 분야	rule	5994	
5	도로터널 분야	explicit	18	
6	도로터널 분야	model	1	
7	도로터널 분야	rule	41	
8	반도체 분야	explicit	20	
9	반도체 분야	rule	1	
10	소방시설(기계/전기) 분야	explicit	1724	
11	소방시설(기계/전기) 분야	model	4923	
12	소방시설(기계/전기) 분야	rule	7561	
13	소방활동 접근성 분야	explicit	684	
14	소방활동 접근성 분야	model	538	
15	소방활동 접근성 분야	rule	2398	
16	화재/피난 시뮬레이션 분야	explicit	502	
17	화재/피난 시뮬레이션 분야	model	134	
18	화재/피난 시뮬레이션 분야	rule	1722	
19				

classified_rows

3만개 데이터 중 아까 지정한 규칙으로 몇 개가 분류됐는지 보여주는 표입니다.

거의 25000개 가까이 분류가 안되었었다라고요 놀랐습니다

아무튼 키워드 추출이 제대로 잘 된건지 잘못된건진 저도 잘 모르겠습니다.
내일 한번만 더 피드백해주시면 감사하겠습니다.